

Análisis, Descomposición y Pronóstico de la Serie de Temperatura Mensual de Bogotá (1851–2013)

Juan Nicolás Patiño Rodríguez

Maestría en Inteligencia Artificial y Ciencia de Datos

Universidad de La Sabana

5 de agosto de 2026

Resumen

Se analiza el histórico de temperatura superficial promedio mensual para 100 ciudades del mundo, con foco en Bogotá, Colombia, entre 1851 y 2013. Tras un análisis gráfico exploratorio y comparativo con ciudades de climas distintos, se aplica una descomposición aditiva de la serie de tiempo y se ajusta un modelo SARIMA para pronosticar su comportamiento futuro. El modelo seleccionado ($\text{SARIMA}(1,0,2) \times (0,1,1,12)_{12}$) alcanza un error de $0,401^\circ\text{C}$ (RMSE) en un conjunto de prueba de 24 meses, y se emplea para proyectar la temperatura de Bogotá 24 meses hacia adelante.

1. Introducción

El estudio de series históricas de temperatura es una herramienta central para caracterizar el comportamiento climático de una región, distinguir su variabilidad estacional de sus tendencias de largo plazo, y anticipar su evolución en el corto y mediano plazo. Con el auge de registros históricos digitalizados a escala global, como el compilado por [Berkeley Earth \(2017\)](#), es posible aplicar sobre estos datos las técnicas de análisis y modelado de series de tiempo que se han consolidado en la literatura estadística ([Box et al., 2015](#); [Hyndman and Athanasopoulos, 2021](#)).

Este informe tiene como objetivo analizar el histórico de temperatura superficial promedio mensual para 100 ciudades del mundo, con un foco particular en **Bogotá, Colombia**, dada la relevancia geográfica de esta ciudad para el contexto del curso. El análisis se estructura en tres etapas, siguiendo los lineamientos de la actividad evaluativa:

1. Un **análisis gráfico** exploratorio de la serie histórica de Bogotá, contrastada con el perfil climático de ciudades de climas marcadamente distintos, para contextualizar sus particularidades antes de profundizar en ella.
2. Una **descomposición de la serie de tiempo** en sus componentes de tendencia, estacionalidad y residuo, que permite aislar y caracterizar cada fuente de variabilidad.
3. Un ejercicio de **modelado y pronóstico** mediante un modelo SARIMA, validado sobre un conjunto de prueba retenido y utilizado posteriormente para proyectar el comportamiento futuro de la serie.

El resto del documento se organiza así: la Sección 2 describe el origen de los datos, el proceso de limpieza y la metodología aplicada en cada etapa; la Sección 3 presenta el análisis gráfico exploratorio; la Sección 4 desarrolla la descomposición de la serie; la Sección 5 documenta el proceso de modelado y pronóstico; la Sección 6 discute críticamente los resultados obtenidos y sus limitaciones; y la Sección 7 sintetiza los hallazgos principales.

2. Datos y Metodología

2.1. Fuente y estructura de los datos

El conjunto de datos utilizado (`Actividad_2_Data.csv`) se deriva del histórico global de temperatura superficial compilado por [Berkeley Earth \(2017\)](#). Cada registro corresponde a la temperatura promedio mensual observada en una ciudad, con las siguientes columnas: `dt` (fecha, primer día del mes), `AverageTemperature` (temperatura promedio en grados Celsius), `AverageTemperatureUncertainty` (incertidumbre de la medición), `City`, `Country`, `Latitude` y `Longitude`. El archivo cubre 100 ciudades entre 1743 y 2013.

2.2. Limpieza de datos

Del total de registros originales, se descartaron aquellos sin temperatura observada (`AverageTemperature` nulo), producto de vacíos en el proceso de medición histórica. Tras esta depuración quedaron 228.175 registros válidos distribuidos entre las 100 ciudades. Las fechas se tipificaron como `datetime` y, para cada ciudad, los registros se ordenaron cronológicamente antes de cualquier análisis posterior.

2.3. Ventana de análisis para Bogotá

Al reindexar la serie de Bogotá a una frecuencia mensual regular se identificó un **vacío continuo de 20 años** (enero de 1830 a junio de 1850, 246 meses consecutivos sin registro), además de un puñado de meses aislados sin dato en otros periodos. Rellenar un vacío de esa magnitud mediante interpolación habría implicado *fabricar* dos décadas de tendencia y estacionalidad inexistentes en los datos, en lugar de simplemente completar huecos puntuales. Por esta razón, el análisis y el modelado se restringen al periodo continuo y confiable de la serie: **1851–2013**, que comprende 1.952 observaciones mensuales sin vacíos relevantes. Los pocos meses aislados sin registro dentro de esta ventana sí se completan mediante interpolación lineal en el tiempo, una operación razonable cuando el hueco es de uno o dos meses.

2.4. Metodología

Análisis gráfico. Se grafica la serie histórica completa de Bogotá y se compara su perfil climático promedio mes a mes contra ciudades representativas de climas distintos (templado boreal, desértico/subtropical, tropical monzónico y templado del hemisferio sur), independientemente del rango de años disponible en cada una. Adicionalmente, se construye un boxplot mensual para inspeccionar la dispersión y detectar valores atípicos por mes.

Descomposición. Se aplica una descomposición clásica de tipo aditivo ($Y_t = T_t + S_t + R_t$) con periodo estacional de 12 meses, mediante la función `seasonal_decompose` de la librería `statsmodels` ([Seabold and Perktold, 2010](#)). Se opta por el modelo aditivo en lugar del multiplicativo porque la amplitud del ciclo estacional de temperatura no muestra una relación proporcional clara con el nivel de la serie.

Modelado y pronóstico. Se divide la serie en un conjunto de entrenamiento y uno de prueba, reservando los últimos 24 meses para validación. Sobre el conjunto de entrenamiento se aplica la prueba de Dickey-Fuller aumentada (ADF) ([Dickey and Fuller, 1979](#)) para evaluar estacionariedad, y se inspeccionan las funciones de autocorrelación (ACF) y autocorrelación parcial (PACF) como insumo para acotar el orden del modelo. El orden final $(p, d, q) \times (P, D, Q)_{12}$ de un modelo SARIMA se selecciona mediante una búsqueda en grilla que minimiza el criterio de información de Akaike (AIC), ajustando los modelos con `SARIMAX` de `statsmodels`. El modelo seleccionado se evalúa sobre el conjunto de prueba mediante el error cuadrático medio (RMSE) y el error

absoluto medio (MAE); posteriormente se reajusta sobre la serie completa para proyectar 24 meses hacia el futuro, junto con su intervalo de confianza del 95 %.

2.5. Herramientas y reproducibilidad

Todo el análisis se implementó en Python con tipado estático estricto (verificado con `mypy -strict`), utilizando `pandas` (McKinney, 2010), `statsmodels` (Seabold and Perktold, 2010), `scikit-learn` y `matplotlib`. Un único script (`src/run_pipeline.py`) ejecuta de punta a punta la carga y limpieza de datos, el análisis gráfico, la descomposición y el modelado, regenerando de forma determinística tanto las figuras como los valores numéricos citados en este informe.

3. Análisis Gráfico

4. Descomposición de la Serie de Tiempo

5. Modelado y Pronóstico

6. Resultados y Discusión

7. Conclusiones

Referencias

- Berkeley Earth (2017). Climate change: Earth surface temperature data. Kaggle dataset. <https://www.kaggle.com/datasets/berkeleyearth/climate-change-earth-surface-temperature-data>.
- Box, G. E. P., Jenkins, G. M., Reinsel, G. C., and Ljung, G. M. (2015). *Time Series Analysis: Forecasting and Control*. Wiley, 5th edition.
- Dickey, D. A. and Fuller, W. A. (1979). Distribution of the estimators for autoregressive time series with a unit root. *Journal of the American Statistical Association*, 74(366):427–431.
- Hyndman, R. J. and Athanasopoulos, G. (2021). *Forecasting: Principles and Practice*. OTexts, Melbourne, Australia, 3rd edition. <https://otexts.com/fpp3/>.
- McKinney, W. (2010). Data structures for statistical computing in python. *Proceedings of the 9th Python in Science Conference*, 445:51–56.
- Seabold, S. and Perktold, J. (2010). statsmodels: Econometric and statistical modeling with python. In *Proceedings of the 9th Python in Science Conference*.